Actividad_3

Análisis de biología computacional

Dra. Yocanxóchitl Perfecto Avalos

Integrantes: José de Jesús Gutiérrez Aldrete, Oscar Miranda Escalante, Luis Humberto Sánchez Vaca, José Gerardo Villanueva Barceló, Ana Ivette Farías Rodríguez

Parte 1

Primero hay que instalar y cargar el paquete "RISmed". También definimos la opción para no se lean los strings como factores.

```
options(stringsAsFactors = F)
#Cargar paquete
install.packages("RISmed")

##
## The downloaded binary packages are in
## /var/folders/j3/89_pjybx40s_g_w578pj92hw0000gn/T//Rtmpq35YSe/downloaded_packages
library(RISmed)
```

Después, hacer query ""colon"[TIAB] AND "cancer"[TIAB] AND "young"[TIAB] AND "incidence"[TIAB] AND ("mutation"[TIAB] OR "treatment"[TIAB] AND "hereditary"[TIAB] OR "apc"[TIAB] OR "TP53"[TIAB] OR "KRAS"[TIAB] OR "pik3ca"[TIAB] OR "fbxw7"[TIAB] OR "smaD4"[TIAB] OR "tcf7l2"[TIAB]OR "nras"[TIAB] OR "early"[TIAB])"

```
#Hacer query
query_colon <- "\"colon\"[TIAB] AND \"cancer\"[TIAB] AND \"young\"[TIAB] AND \"incidence\"[TIAB] AND (\
#Instrucción para crear un query
search_query <- EUtilsSummary(query_colon)

#Hacer un resumen de la búsqueda
summary(search_query)
```

```
## Query:
## "colon"[TIAB] AND "cancer"[TIAB] AND "young"[TIAB] AND "incidence"[TIAB] AND ("mutation"[TIAB] OR "t
## Result count: 78
```

Obtener datos de los artículos

```
#Ejecutar la búsqueda para obtener los datos de PUBMED
records <- EUtilsGet(search_query)</pre>
#Con esta instrucción obtenemos el título, abstract y el PUBMED ID
pubmed_data <-data.frame('Title'=ArticleTitle(records), 'Abstract'=AbstractText(records), 'PID'=Article</pre>
dim(pubmed_data)
## [1] 78 3
pubmed_data[1,]
## 1 Molecular Aspects of Colorectal Adenomas: The Interplay among Microenvironment, Oxidative Stress,
                   PID
     Abstract
## 1
              32258104
pubmed_data[1:3,c("Title","PID")]
##
                          Molecular Aspects of Colorectal Adenomas: The Interplay among Microenvironment
## 2 Clinical characteristics and a rising incidence of early-onset colorectal cancer in a nationwide c
                                            International incidence trends in early- and late-onset color
## 3
##
          PID
## 1 32258104
## 2 32234586
## 3 32173775
Preprocesar datos
#Eliminar algunos caracteres del título y del abstract
pubmed_data$Title <- gsub(pattern="\\.|:|,|;|\\[|\\]", replacement="", pubmed_data$Title)</pre>
pubmed_data$Abstract <- gsub(pattern="\\.|:|,|;|\\[|\\]", replacement="", pubmed_data$Abstract)</pre>
#Pasar todo a minúsculas
pubmed_data$Title <- tolower(pubmed_data$Title)</pre>
pubmed_data$Abstract <- tolower(pubmed_data$Abstract)</pre>
pubmed_data[1,]
##
## 1 molecular aspects of colorectal adenomas the interplay among microenvironment oxidative stress and
     Abstract
                   PID
              32258104
## 1
length(pubmed_data$Title)
## [1] 78
```

Obtener las palabras del abstract

```
#Con strsplit podemos separar las palabras por espacio
unlist(strsplit(pubmed_data$Abstract[1], " "))[1:10]
   [1] NA NA NA NA NA NA NA NA NA
Problemas con algunos abstracts
#Artículos de los cuales no se obtiene el abstract
which(pubmed_data$Abstract == "")
## [1] 1 5 21
Obtener las palabras del abstract
#Obtener las palabras en un data frame junto con el PUBMED ID
# data frame para guardar las palabras
word_list <- c()</pre>
#Ciclo para todos los abstracts
for(i in 1:length(pubmed_data$Abstract)){
    #Obtener las palabras como vector en lugar de lista
    aux_word <- unlist(strsplit(pubmed_data$Abstract[i], " "))</pre>
    #Si el abstract tiene palabras
    if(length(aux_word) > 0){
        #Se juntan las palabras y el PUBMED ID
        aux_list <- cbind(pubmed_data$PID[i], aux_word)</pre>
        #Se pega este data frame auxiliar al que guarda todo
        word_list <- rbind(word_list, aux_list)</pre>
    }}
colnames(word_list) <- c("PID","Word")</pre>
dim(word_list)
## [1] 22091
word_list[1:5,]
##
        PID
                    Word
## [1,] "32234586" "background"
## [2,] "32234586" "the"
## [3,] "32234586" "incidence"
## [4,] "32234586" "of"
## [5,] "32234586" "early-onset"
Quitar "stopwords"
```

```
## Loading required package: NLP
```

#Cargar paquete tm
#install.packages("tm")

library(tm)

```
#Obtener stopwords en ingles
stop_words <- stopwords(kind="en")</pre>
stop_words
     [1] "i"
                        "me"
                                      "mv"
                                                                   "we"
##
                                                     "myself"
##
     [6] "our"
                        "ours"
                                                     "vou"
                                                                   "your"
                                      "ourselves"
    [11] "yours"
                        "yourself"
                                                     "he"
                                                                   "him"
##
                                      "yourselves"
##
    [16] "his"
                        "himself"
                                      "she"
                                                     "her"
                                                                   "hers"
##
                        "it"
                                      "its"
    [21] "herself"
                                                     "itself"
                                                                   "they"
##
    [26] "them"
                        "their"
                                      "theirs"
                                                     "themselves"
                                                                   "what"
    [31] "which"
                        "who"
                                                     "this"
                                                                   "that"
##
                                      "whom"
##
    [36] "these"
                        "those"
                                      "am"
                                                     "is"
                                                                   "are"
                        "were"
                                      "be"
##
    [41] "was"
                                                     "been"
                                                                   "being"
                        "has"
##
    [46] "have"
                                      "had"
                                                     "having"
                                                                   "do"
                                                                   "should"
##
    [51] "does"
                        "did"
                                      "doing"
                                                     "would"
##
    [56] "could"
                        "ought"
                                      "i'm"
                                                     "you're"
                                                                   "he's"
##
    [61] "she's"
                        "it's"
                                      "we're"
                                                     "thev're"
                                                                   "i've"
    [66] "you've"
                        "we've"
                                      "thev've"
                                                     "i'd"
                                                                   "you'd"
##
##
    [71] "he'd"
                        "she'd"
                                      "we'd"
                                                     "thev'd"
                                                                   "i'll"
                                                                   "they'll"
##
    [76] "you'll"
                        "he'll"
                                      "she'll"
                                                     "we'll"
    [81] "isn't"
                        "aren't"
                                      "wasn't"
                                                     "weren't"
                                                                   "hasn't"
##
    [86] "haven't"
                        "hadn't"
                                                                   "didn't"
                                      "doesn't"
                                                     "don't"
##
##
    [91] "won't"
                        "wouldn't"
                                      "shan't"
                                                     "shouldn't"
                                                                   "can't"
   [96] "cannot"
                                                     "let's"
##
                        "couldn't"
                                      "mustn't"
                                                                   "that's"
## [101] "who's"
                        "what's"
                                      "here's"
                                                     "there's"
                                                                   "when's"
## [106] "where's"
                        "why's"
                                      "how's"
                                                     "a"
                                                                   "an"
                                      "but"
                                                     "if"
                                                                   "or"
## [111] "the"
                        "and"
                                                                   "of"
## [116] "because"
                        "as"
                                      "until"
                                                     "while"
                        "by"
## [121] "at"
                                      "for"
                                                     "with"
                                                                   "about"
## [126] "against"
                                      "into"
                        "between"
                                                     "through"
                                                                   "during"
                                                                   "to"
## [131] "before"
                        "after"
                                      "above"
                                                     "below"
## [136] "from"
                        "up"
                                      "down"
                                                     "in"
                                                                   "out"
## [141] "on"
                        "off"
                                      "over"
                                                     "under"
                                                                   "again"
                        "then"
                                                     "here"
                                                                   "there"
## [146] "further"
                                      "once"
                        "where"
                                      "why"
                                                     "how"
                                                                   "all"
## [151] "when"
## [156] "any"
                        "both"
                                      "each"
                                                     "few"
                                                                   "more"
## [161] "most"
                        "other"
                                      "some"
                                                     "such"
                                                                   "no"
## [166] "nor"
                        "not"
                                      "only"
                                                     "own"
                                                                   "same"
## [171] "so"
                        "than"
                                      "too"
                                                     "very"
#Palabras que son stopwords
index_stop_word <- which(word_list[,2] %in% stop_words)</pre>
length(index_stop_word)
## [1] 7640
#Quitar stopwords
word_list <- word_list[-index_stop_word,]</pre>
dim(word_list)
```

[1] 14451

2

Palabras más frecuentes

```
#Instrucción table y sort para obtener una tabla y ordenarla
sort(table(word_list[,2]), decreasing=T)[1:10]
##
##
       cancer
                patients incidence
                                            crc colorectal
                                                                  age
                                                                           young
##
          403
                                            205
                                                       185
                                                                  180
                                                                              168
                     313
                                232
##
        colon
                   years
                              among
##
          147
                     133
                                128
Dejar una combinación palabra-documento
#Crear un data frame y agregar una columna con la combinación PID_palabra
word_df <- data.frame(PID=as.numeric(word_list[,1]), Word=word_list[,2],</pre>
PIDWord=as.character(apply(word_list, 1, paste, collapse="_")))
word_df[1:5,]
##
                                       PIDWord
          PID
                     Word
## 1 32234586 background 32234586_background
## 2 32234586
                incidence
                            32234586_incidence
## 3 32234586 early-onset 32234586_early-onset
## 4 32234586 colorectal 32234586_colorectal
## 5 32234586
                   cancer
                               32234586_cancer
Quitar repetidos usando duplicated
#Obtener duplicados
dup_index <- duplicated(word_df$PIDWord)</pre>
word_df$PIDWord[1:10]
  [1] "32234586_background"
                               "32234586_incidence"
                                                       "32234586_early-onset"
  [4] "32234586_colorectal"
                               "32234586_cancer"
                                                       "32234586_(eocrc)"
## [7] "32234586_reported"
                                "32234586 increase"
                                                       "32234586_patients"
## [10] "32234586_eocrc"
dup_index[1:10]
   [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
length(which(dup_index))
## [1] 5842
Quitar duplicados
#Quitar duplicados
dim(word_df)
## [1] 14451
                 3
```

```
word_df <- word_df[-which(dup_index),]
dim(word_df)</pre>
```

```
## [1] 8609 3
```

Palabras más frecuentes

```
#Instrucción table y sort para obtener una tabla y ordenarla sort(table(word_df$Word), decreasing=T)[1:10]
```

```
##
                                                                               patients
##
    incidence
                    cancer
                                 young
                                             colon colorectal
                                                                        age
##
            73
                        71
                                    66
                                                 64
                                                             57
                                                                         55
                                                                                      53
##
        early
                                 study
                     years
                                    35
##
            42
                        42
```

-Revisar que hayas obtenido la misma cantidad de artículos en la búsqueda manual como en la hecha con R: La búsqueda manual en PubliMed arrojo una cantidad de 81 artículos. La diferencia se debe a que la información no ha sido actualizada para RISmed. Probablemente se hayan omitido los 3 artículos más recientes.

-Usando los resultados en R, obtén las 10 palabras más frecuentes y da una interpretación de la enfermedad. Sólo considera palabras relacionadas a medicina, es decir evita artículos, adverbios, adjetivos, etc. Estudios demuestran que la incidencia en edades tempranas del cáncer de colon/colorrectal ha aumentado, acrecentando la cantidad de pacientes jóvenes.